

## 高斯过程回归

数学推导

回归过程

适用范围

实现

## 灰色关联分析

适用范围

使用步骤

## ARMA时序模型

# 高斯过程回归

前言：在2018C中关于1B的解法中，某团队使用了高斯过程回归预测模型（GPR，得到函数 $f(x)$ 的分布），旨在展现出历史能源的演变。

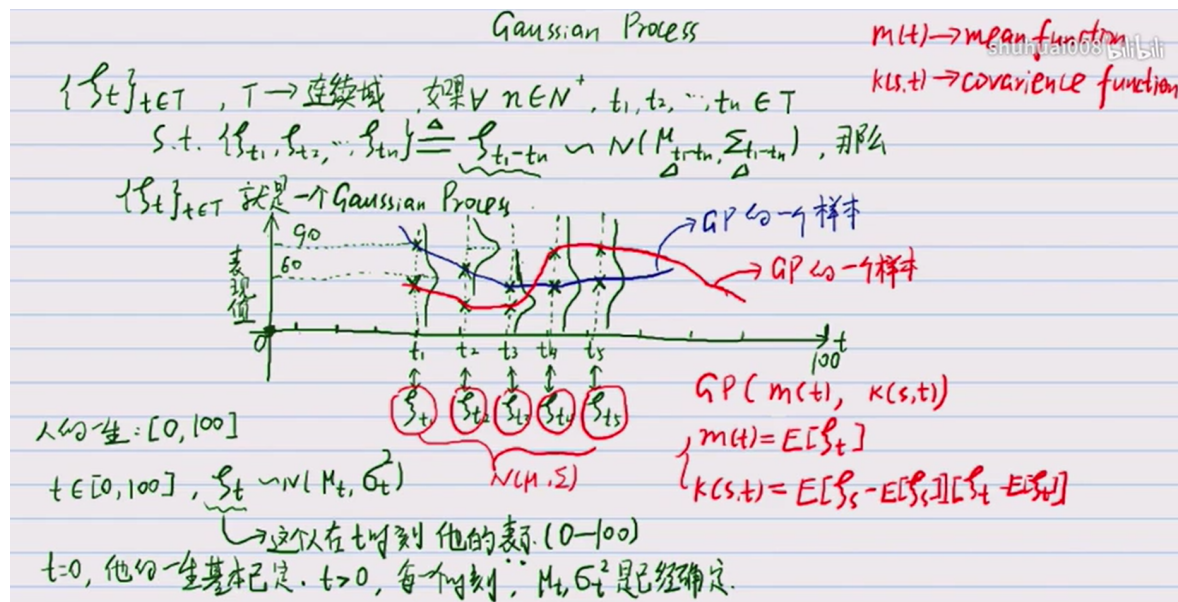
指标---->GPR得到目标值的分布---->演变过程。

## 数学推导

### 推导视频

高斯过程是无限维的高斯分布

### 1、高斯过程解释（一个随机过程）



### 2、高斯过程回归（基于贝叶斯分布）

前提：变量满足高斯分布

两个视角

- 权重空间
- 函数空间（更容易理解）

GPR:

① weight-space view : 关注的是  $w$

② function-space view ; 关注的是  $f(x)$

$$x^*, \rightarrow y^*$$

$$P(y^* | \text{Data}, x^*) = \int_w P(y^* | w, x^*) \cdot P(w) dw$$

$$P(y^* | \text{Data}, x^*) = \int P(y^* | f, x^*) \cdot P(f) df$$

## 回归过程

对于数据集  $D : (X, Y)$ , 令  $f(x_i) = y_i$ , 从而得到向量  $f = [f(x_1), f(x_2), \dots, f(x_n)]$ , 将所需要预测的  $x_i$  的集合定义为  $X^*$ , 对应的预测值为  $f^*$ , 根据贝叶斯公式有:

$$p(f^* | f) = \frac{p(f | f^*) p(f^*)}{p(f)} = \frac{p(f, f^*)}{p(f)}$$

高斯回归首先要计算数据集中样本之间的联合概率分布,  $f \sim N(\mu, K)$ ,  $\mu$  为  $f(x_1), f(x_2), \dots, f(x_n)$  的均值所组成的向量,  $K$  为其协方差矩阵, 再根据需要预测的  $f^*$  的先验概率分布  $f^* \sim N(\mu^*, K^*)$  与  $f \sim N(\mu, K)$ , 来计算出  $f^*$  的后验概率分布。

### 1、计算 $p(f)$ 的先验分布。

原始数据、协方差矩阵 (选择适合的核函数)

(1) 协方差矩阵必须是半正定阵

(2) kernel fountion 都是半正定阵。这就意味着我们在学习 SVM 的时候所学过的核函数形式都可以用

当然应用最广的是 RBF kernel, 即如下式:

$$k(x, x') = \alpha^2 \exp(-\frac{1}{2l^2})(x - x')^2)$$

其中  $\alpha$  为超参数,  $l$  是需要通过学习进行确定的参数, 那么我们只需要通过监督学习的方式学习到合适的 kernel, 即可很方便的计算出  $f$  的协方差矩阵。

如何学习 kernel 的参数? 很简单 kernel  $k(x, x')$  优劣的评价标准就是在要  $f(x) \sim N(m(x), k(x, x^T))$  的条件下, 让  $p(Y|X)$  最大, 为了方便求导我们将目标函数设为  $\log p(Y|X) = \log N(\mu, K_y)$ , 接下来利用梯度下降法来求最优值即可:

$$\frac{\partial \log p(Y|X)}{\partial \theta} = \frac{1}{2} y^T K_y^{-1} \frac{\partial K_y}{\partial \theta} K_y^{-1} y - \frac{1}{2} \text{tr}(K_y^{-1} \frac{\partial K_y}{\partial \theta})$$

### 2、联合概率分布的先验概率

已知  $f(x) \sim N(\mu, K)$ ,  $f(x^*) \sim N(\mu^*, K(x^*, x^*))$ , 可计算其联合概率分布的先验:

$$\begin{pmatrix} f \\ f^* \end{pmatrix} \sim \left( \begin{pmatrix} \mu \\ \mu^* \end{pmatrix}, \begin{pmatrix} K & K^* \\ K^{*T} & K^{**} \end{pmatrix} \right)$$

其中  $K^{**}$  为  $f(x^*)$  的协方差矩阵,  $K^{**} = k(X^*, X^*)$ ,  $K^* = k(X, X^*)$

### 3、根据贝叶斯公式，求后验概率并估算

有了 $p(f)$ 的先验分布，以及上面计算的 $p(f, f^*)$ ，根据贝叶斯公式可以计算 $p(f^* | f)$ 的后验概率：

$$p(f^* | f) = \frac{p(f | f^*)p(f^*)}{p(f)} = \frac{p(f, f^*)}{p(f)}$$

从而得出对于 $f^*$ 的估计， $f^* \sim (\mu', K')$

$$\mu' = K^T K^{-1} f$$

$$K' = K^*{}^T K^{-1} K^* + K^{**}$$

依据原始数据和预测数据之间的协方差，判断y值的差异性，根据概率公式得到预测值

## 适用范围

一般回归算法给定输入X，希望得到的是对应的Y值；但是该高斯过程回归的目标是求出y的分布，因此可以适用于求解/预测某变量变化/演化情况的题目。

## 实现

可以调用sklearn库中的gaussian\_process库

## 灰色关联分析

### 适用范围

用于系统分析：探究对于一个系统，哪些是印象其发展的主要/次要因素。

### 使用步骤

#### 第一步：确定分析数列

确定反映系统行为特征的参考数列和影响系统行为的比较数列。反映系统行为特征的数据序列，称为参考数列。影响系统行为的因素组成的数据序列，称比较数列。

进行分析的母序列、子序列

#### 第二步，变量的无量纲化

由于系统中各因素列中的数据可能因量纲不同，不便于比较或在比较时难以得到正确的结论。因此在进行灰色关联度分析时，一般都要进行数据的无量纲化处理。主要有一下两种方法：

(1) 初值化处理： $x_i(k) = \frac{x_i(k)}{x_i(1)}$ ,  $k = 1, 2 \dots n$ ;  $i = 0, 1, 2 \dots m$

(2) 均值化处理： $x_i(k) = \frac{x_i(k) - \bar{x}_i}{\bar{x}_i}$ ,  $k = 1, 2 \dots n$ ;  $i = 0, 1, 2 \dots m$

其中 $k$ 对应时间段， $i$ 对应比较数列中的一行（即一个特征）

#### 第三步，计算关联系数

$$\xi_i(k) = \frac{\min_i \min_k |y(k) - x_i(k)| + \rho \max_i \max_k |y(k) - x_i(k)|}{|y(k) - x_i(k)| + \rho \max_i \max_k |y(k) - x_i(k)|}$$

记 $\Delta_i(k) = |y(k) - x_i(k)|$ , 则

$$\xi_i(k) = \frac{\min_i \min_k \Delta_i(k) + \rho \max_i \max_k \Delta_i(k)}{\Delta_i(k) + \rho \max_i \max_k \Delta_i(k)}$$

$\rho$  代表 分辨系数, 一般取0.5

#### 第四步, 计算关联度

因为关联系数是比较数列与参考数列在各个时刻 (即曲线中的各点) 的关联程度值, 所以它的数不止一个, 而信息过于分散不便于进行整体性比较。因此有必要将各个时刻 (即曲线中的各点) 的关联系数集中为一个值, 即求其平均值, 作为比较数列与参考数列间关联程度的数量表示,

对系数逐一累加再求均值

第五步:关联度排序,找到相似度最大的两序列

## ARMA时序模型

#### [参考链接](#)

```
from statsmodels.tsa.arima_model import ARMA
```

本质就是用前期的数据预测未来短时间内的数据

重点是对数据的平滑处理和噪音检测, 分解出数据的趋势和周期性数据,